



Création et utilisation de la base de données

Sophana SEAN
12 Novembre 2025



Contexte du projet

- **Projet d'analyse de données immobilières basées sur les valeurs foncières en France pour le 1er semestre 2020.**
- **Sources** : Fichiers Excel (donnees_communes, Valeurs-foncières, referentiel-geographique).
- **Objectifs** : Comprendre les données, créer un schéma relationnel, charger une base SQLite, et extraire des insights via SQL (ex. : ventes d'appartements, prix au m²).
- **Outils** : Pandas pour transformation, SQLite pour la base, dbdiagram.io pour le schéma.



La stratégie de sauvegarde et la conformité RGPD

1. Data-minimization (RGPD Art. 5)

- Suppression systématique des colonnes vides ou >99 % vides
- Conservation uniquement des colonnes >1 % de données non vides ET pertinentes
- Exemple : 27 colonnes sur 41 écartées dans Valeurs-foncières.xlsx

2. Pas de données personnelles sensibles

- Aucun nom/prénom complet (champ « Nom de l'acquéreur » conservé mais non exploité)
- Aucun numéro fiscal, adresse exacte ou données de contact

3. Anonymisation géographique

- Utilisation exclusive des codes INSEE (CODDEP, CODCOM)
- Géolocalisation conservée uniquement sous forme « lat,lon » (précision quartier, pas adresse)

4. Stratégie de sauvegarde

- Base locale : immo_vente.sqlite (fichier unique, chiffrable via BitLocker/VeraCrypt)
- Export CSV dans dossier sécurisé (CSV/) avec contrôle d'accès
- Versionning Git (commit réguliers) + backup externe chiffré hebdomadaire
- Suppression automatique des DataFrames en RAM après insertion

Les données initiales

- Trois fichiers sources :
 - donnees_communes.xlsx : Infos sur les communes (population, codes INSEE).
 - Valeurs-foncières.xlsx : Détails des transactions (date, valeur, type de bien).
 - fr-esr-referentiel-geographique.xlsx : Référentiel géographique (régions, départements, coordonnées).
- Analyse initiale : Colonnes vides exclues (ex. : seules celles avec >1% de données conservées).
- Exemple de structure (tableau simple) :

Fichier	Colonnes clés
donnees_communes	CODREG, CODDEP, COM, PMUN, PTOT
Valeurs-foncières	Date mutation, Valeur fonciere, Type local
referentiel-geographique	reg_nom, dep_nom, com_nom, geolocalisation

L'extrait du dictionnaire des données

- Extrait pour donnees_communes.xlsx :


Code	Description	Type	Clé	Règle de Gestion
CODREG	Code région	String	FK	Code INSEE valide
CODDEP	Code département	String	FK	Code INSEE (ex: '01')
PTOT	Population totale	Integer		PTOT = PMUN + PCAP

- Extrait pour Valeurs-foncières.xlsx :

Code	Description	Type	Clé	Règle de Gestion
Date mutation	Date de vente	Date		Convertir en standard
Valeur fonciere	Montant (€)	Float		Valeur positive
Type local	Type bien	String		Ex: Maison, Appartement


Le schéma relationnel normalisé

Modélisé avec dbdiagram.io



La base de données avec les tables créées et les données chargées

- Base SQLite : immo_vente.sqlite.
- Création tables via classe DatabaseManager (connexion, execute_sql).
- Chargement : Pandas to_sql pour insérer dataframes (commune, bien, vente, dep).
- Vérification : SELECT name FROM sqlite_master → Tables : Departement, Commune, Bien, Vente.



id_bien	id_codedep_codecommune	no_voie	btq	type_voie	voie	total_piece	surface_carrez	surface_local	type_local	prix_m2
1	01103	347		RUE	DU CHATEAU	3	48.22	48	Appartement	3421.82
2	06004	4		BD	EDOUARD BAUDOIN	1	39.11	40	Appartement	9094.35
3	06088	20	B	RUE	MARCEAU	3	80.25	82	Appartement	2859.81
4	06123	550		RTE	DES VESPINS RN7	1	27.51	27	Appartement	4543.8
5	13005	9300		RES	LES ARPEGES BD DES ABA	2	47.33	47	Appartement	1901.54
6	13028	27		RUE	DU GRAND MADIER	1	25.31	24	Appartement	3674.44
7	13208	360		AV	DU PRADO	3	70.84	70	Appartement	4208.07
8	13212	5076	F	PARC	DESSUARD	3	67.19	66	Appartement	2433.4

Les requêtes ou screenshot qui permettent de démontrer le bon chargement des données

- Requête test : `SELECT COUNT(*) FROM [Table]` pour vérifier le nombre de lignes.
- Exemple : Top 3 biens les plus chers (code d'Exercice2.ipynb)

```
SELECT b.id_codedep_codecommune, c.nom_commune, b.prix_m2, c.population_totale, v.trimestre
FROM Bien b
JOIN Commune c ON b.id_codedep_codecommune = c.id_codedep_codecommune
JOIN Vente v ON b.id_bien = v.id_bien
ORDER BY b.prix_m2 DESC LIMIT 3
```

Résultat :

```
[('75116', 'Paris 16e Arrondissement', 989010.99, 167777, '2020Q2'),
 ('75110', 'Paris 10e Arrondissement', 673480.0, 86863, '2020Q2'),
 ('75107', 'Paris 7e Arrondissement', 417406.96, 49681, '2020Q1')]
```




Requêtes SQL et résultats

Requêtes

1 - Nombre total d'appartements vendus au 1er semestre 2020

```
SELECT COUNT(b.type_local) as "Nb appartement"
  FROM Bien b
  JOIN Vente v ON b.id_bien = v.id_bien
  WHERE b.type_local = "Appartement"
  AND v.date BETWEEN '2020-01-01' AND
'2020-06-30'
```

30937

2 - Nombre de ventes d'appartements par région

```
SELECT COUNT(*) as "Nb vente", c.reg_nom
  FROM Vente v
  JOIN Bien b ON b.id_bien = v.id_bien
  JOIN Commune c ON c.id_codedep_codecommune
= b.id_codedep_codecommune
  WHERE v.date BETWEEN '2020-01-01' AND
'2020-06-30'
  GROUP BY c.reg_nom
```

(3443, 'Auvergne-Rhône-Alpes'), (399, 'Bourgogne-Franche-Comté'),
(1036, 'Bretagne'), (766, 'Centre-Val de Loire'),
(251, 'Corse'), (1026, 'Grand Est'), (2, 'Guadeloupe')...

Requêtes

3 - Proportion des ventes par nombre de pièces

```
SELECT
    b.total_piece AS "Nb pièces",
    COUNT(*) AS "Nombre de ventes",
    ROUND(100.0 * COUNT(*) / SUM(COUNT(*))
OVER (), 2) || '%' AS "Proportion des ventes"
FROM Vente v
JOIN Bien b ON v.id_bien = b.id_bien
GROUP BY b.total_piece
ORDER BY b.total_piece;
```

```
[NB Pièce][NB Vente][Proportion]
(0, 33, '0.1%'), (1, 6800, '19.9%'), (2, 10050, '29.41%'),
(3, 9568, '28.0%'), (4, 5534, '16.2%'), (5, 1671, '4.89%'),
(6, 369, '1.08%'), (7, 98, '0.29%'), (8, 28, '0.08%'),
(9, 13, '0.04%'), (10, 4, '0.01%'), (11, 1, '0.0%')
```

4 - Top 10 départements prix m² élevé

```
SELECT d.nom_departement, MAX(b.prix_m2) AS
prix_m2_max
FROM Departement d
JOIN Commune c ON c.code_departement =
d.code_departement
JOIN Bien b ON b.id_codedep_codecommune =
c.id_codedep_codecommune
GROUP BY d.nom_departement
ORDER BY prix_m2_max DESC LIMIT 10
```

```
('Paris (75)', 989010.99), ('Val-de-Marne (94)', 262318.84),
('Loiret (45)', 221297.71), ('Yvelines (78)', 187117.58),
('Essonne (91)', 134375.0), ('Hautes-Alpes (05)', 126850.0)...
```

Requêtes

5 - Prix moyen m² maison Île-de-France

```
SELECT AVG(b.prix_m2) AS prix_m2_moyen,  
c.reg_nom  
  FROM Bien b  
  JOIN Commune c ON b.id_codedep_codecommune  
 = c.id_codedep_codecommune  
 WHERE b.type_local = "Maison"  
       AND c.reg_nom = "Ile-de-France"
```

(3745.0873559962224, 'Ile-de-France')

6 - Top 10 appartements les plus chers (2 réponses)

```
SELECT b.id_bien, v.valeur, b.prix_m2,  
c.reg_nom  
  FROM Bien b  
  JOIN Commune c ON b.id_codedep_codecommune  
 = c.id_codedep_codecommune  
  JOIN Vente v ON v.id_bien = b.id_bien  
 WHERE b.type_local = "Appartement"  
       ORDER BY v.valeur DESC LIMIT 10
```

[ID Bien] [Valeur] [Prix M²] [Région]

(30603, 9000000, 989010.99, 'Ile-de-France'),
(5261, 8600000, 134375.0, 'Ile-de-France'),
(3625, 8577713, 417406.96, 'Ile-de-France'),
(7602, 7620000, 178162.26, 'Ile-de-France'),
(9988, 7600000, 30003.95, 'Ile-de-France')...

Requêtes

7 - Taux d'évolution du nombre de ventes entre le premier et le second trimestre de 2020

```
SELECT
    ROUND(100.0 * (v2.ventes - v1.ventes) /
v1.ventes, 2) || ' %' AS evolution_T1_vers_T2,
v1.ventes, v2.ventes
    FROM (
        SELECT COUNT(*) AS ventes
        FROM Vente
        WHERE trimestre = '2020Q1'
    ) v1,
    (
        SELECT COUNT(*) AS ventes
        FROM Vente
        WHERE trimestre = '2020Q2'
    ) v2;
```

[Taux evol][Nb Vente T1][Nb vente T2]
[('3.68 %', 16776, 17393)]

8 - Le classement des régions par rapport au prix au mètre carré des appartement de plus de 4 pièces

```
SELECT c.reg_nom, AVG(b.prix_m2) as
moyenne_prix_m2
    FROM Commune c
    JOIN Bien b ON b.id_codedep_codecommune =
c.id_codedep_codecommune
    WHERE b.type_local = "Appartement"
    AND b.total_piece > 4
    GROUP BY c.reg_nom
    ORDER BY moyenne_prix_m2 DESC
```

('Ile-de-France', 8770.442894736843),
('La Réunion', 3641.815),
('Provence-Alpes-Côte d'Azur', 3587.653675213675),
('Corse', 3104.882),
('Auvergne-Rhône-Alpes', 2891.3777297297297)...

Requêtes

9 - Liste des communes ayant eu au moins 50 ventes au 1er trimestre

```
SELECT c.nom_commune, COUNT(v.id_vente) as
nb_vente
  FROM Vente v
  JOIN Bien b ON v.id_bien = b.id_bien
  JOIN Commune c ON b.id_codedep_codecommune
= c.id_codedep_codecommune
 WHERE v.trimestre LIKE "%Q1"
  GROUP BY c.nom_commune
  HAVING nb_vente >= 50
```

('Ajaccio', 54), ('Angers', 64), ('Antibes', 77),
('Asnières-sur-Seine', 81), ('Bordeaux', 157),
('Boulogne-Billancourt', 99), ('Courbevoie', 80),
('Grenoble', 106), ('Issy-les-Moulineaux', 50)...

10 - Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces.

```
SELECT ROUND(100.0 * (avg2.moyenne -
avg1.moyenne) / avg1.moyenne, 2) || ' %' ,
avg1.moyenne, avg2.moyenne
  FROM (
    SELECT AVG(prix_m2) AS moyenne
    FROM Bien
    WHERE total_piece = 2
  ) avg1,
  ( SELECT AVG(prix_m2) AS moyenne
    FROM Bien
    WHERE total_piece = 3
  ) avg2;
```

Si la valeur est négative, la moyenne du m² d'un appart T3 est moins cher par rapport à un T2 -12.86 %

[Taux evol] [Moyenne prix m² T2] [Moyenne prix m² T3]

[['-12.86 %', 4870.055339641434, 4243.7128125]]

Requêtes

11 - Les moyennes de valeurs foncières pour le top 3 des communes des départements 6, 13, 33, 59 et 69.

```
SELECT ROUND(AVG(max_top3.valeurBien),2), max_top3.codeDep, d.nom_departement
FROM (
    SELECT * FROM (
        SELECT v.valeur as valeurBien, c.nom_commune as nomCommune, c.code_departement as codeDep,
            ROW_NUMBER() OVER (
                PARTITION BY c.code_departement
                ORDER BY v.valeur DESC
            ) AS rang
        FROM Vente v
        JOIN Bien b ON v.id_bien = b.id_bien
        JOIN Commune c ON b.id_codedep_codecommune = c.id_codedep_codecommune
    )
    WHERE rang < 4
    AND codeDep IN ('06', '13', '33', '59', '69')
) max_top3
JOIN Departement d ON d.code_departement = max_top3.codeDep
GROUP BY max_top3.codeDep
```

(2220000, 'Roquebrune-Cap-Martin', '06', 1), (1996150, 'Villefranche-sur-Mer', '06', 2), (1852500, 'Nice', '06', 3), (1000000, 'Marseille 14e Arrondissement', '13', 1), (725000, 'Marseille 7e Arrondissement', '13', 2), (700000, 'Marseille 14e Arrondissement', '13', 3), (1390000, 'Lège-Cap-Ferret', '33', 1)...

Requêtes

Requête 11 - 2ème solution

```
WITH Moyennes AS (  
    SELECT  
        c.code_departement AS codeDep, c.nom_commune, AVG(v.valeur) AS moyenne_valeur  
    FROM Vente v  
    JOIN Bien b ON v.id_bien = b.id_bien  
    JOIN Commune c ON b.id_codedep_codecommune = c.id_codedep_codecommune  
    WHERE c.code_departement IN ('06', '13', '33', '59', '69')  
    GROUP BY c.code_departement, c.nom_commune  
) ,  
Classement AS (  
    SELECT  
        codeDep, nom_commune, moyenne_valeur, ROW_NUMBER() OVER (  
            PARTITION BY codeDep  
            ORDER BY moyenne_valeur DESC  
        ) AS rang  
    FROM Moyennes  
)  
SELECT  
    codeDep, nom_commune, ROUND(moyenne_valeur, 0) AS moyenne_valeur  
FROM Classement  
WHERE rang < 4  
ORDER BY codeDep, rang;
```

('06', 'Saint-Jean-Cap-Ferrat', 968750.0), ('06', 'Eze', 655000.0), ('06', 'Mouans-Sartoux', 476898.0), ('13', 'Gignac-la-Nerthe', 330000.0),
('13', 'Saint-Savournin', 314425.0), ('13', 'Cassis', 313417.0), ('33', 'Lège-Cap-Ferret', 549501.0), ('33', 'Vayres', 335000.0)...

Requêtes

12 - Les 20 communes avec le plus de transactions pour 1000 habitants pour les communes qui dépassent les 10000 habitants.

```
SELECT
    c.nom_commune, c.code_departement, COUNT(v.id_vente), c.population_totale,
    ROUND((COUNT(v.id_vente) * 1000.0 / c.population_totale),2) AS ventes_pour_1000_habitants
FROM Vente v
JOIN Bien b ON v.id_bien = b.id_bien
JOIN Commune c ON b.id_codedep_codecommune = c.id_codedep_codecommune
WHERE c.population_totale > 10000
GROUP BY c.nom_commune, c.code_departement, c.population_totale
ORDER BY ventes_pour_1000_habitants DESC
LIMIT 20;
```

[Commune] [N° Dep] [Nb vente] [Population totale] [Ventes pour 100 habitants]

```
('Paris 2e Arrondissement', '75', 127, 21735, 5.84),
('Paris 1er Arrondissement', '75', 79, 16055, 4.92),
('Paris 3e Arrondissement', '75', 161, 34306, 4.69),
('Arcachon', '33', 55, 11898, 4.62),
('La Baule-Escoublac', '44', 77, 16797, 4.58),
('Paris 4e Arrondissement', '75', 120, 29390, 4.08), ...
```



Merci !