

AUDIT : Erreur sur le Cube OLAP



SUPER SMART MARKET



Présentation de la mission

Hugo m'a confié une mission express : comprendre pourquoi le chiffre d'affaires du 14 août 2024 est passé de 275 186,59 € à 284 243,88 € en deux jours soit une différence de **9057,29 €**, alors que les magasins étaient fermés le 15 août et qu'aucune vente supplémentaire n'a eu lieu.

À cela s'ajoutait un second problème : les chiffres du jour n'étaient pas stables et variaient d'un recalcul à l'autre.


J'ai dû reconstruire un prototype fidèle de la base OLAP en local, analysé les 207 000 lignes de logs, identifier la cause racine et valider les chiffres exacts demandés (CA total + top 10 clients + top 10 employés).

Analyse de la base de données

Architecture de l'entreprise

Architecture OLAP Actuelle

- Source : Fichiers Excel (cube_14082024.xlsx) + Logs externes (Logs.xlsx)
- Flux : ETL vers base OLAP → Power BI pour rapports
- Tables principales :
 - Faits : Vente_Detail (ventes + liens)
 - Dimensions : Produits, Clients, Employé, Calendrier
- Problème : Logs non intégrés → pas de traçabilité des échecs





Analyse de la base de données

Dictionnaire des données du fichier OLAP

Table : **vente_detail**

Colonne	Description	Type	Clé	Longueur	Nature	Règle
ID_BDD	ID ligne vente	INTEGER	PK	N/A	Identifiant	Auto-incr, NOT NULL
CUSTOMER_ID	ID client	VARCHAR(50)	FK (Clients)	50	Référence	Existant en Clients
id_employe	ID employé	INTEGER	FK (Employé)	N/A	Référence	Peut être NULL
EAN	Code produit	CHAR(13)	FK (Produits)	13	Code	Format EAN13 valide
Date_achat	Date/heure achat	DATETIME	-	N/A	Temporel	ISO 8601, NOT NULL
ID_ticket	ID ticket	VARCHAR(50)	-	50	Identifiant	Unique par ticket

Table : produits

Colonne	Description	Type	Clé	Longueur	Nature	Règle
EAN	Code GTIN/EAN-13 du produit	CHAR	PK	13	Clé produit	Unique, format EAN-13 strict
categorie	Catégorie commerciale	VARCHAR	–	100	Descriptive	Référentiel contrôlé
rayon	Rayon physique dans le magasin	VARCHAR	–	100	Descriptive	Standardisé
libelle_produit	Libellé complet du produit	VARCHAR	–	255	Descriptive	Max 255 caractères, trim
prix	Prix unitaire TTC actuel	DECIMAL(10,2)	–	–	Monétaire	≥ 0, exactement 2 décimales

Table : clients

Colonne	Description	Type	Clé	Longueur	Nature	Règle
CUSTOMER_ID	Identifiant unique du client	VARCHAR	PK	50	Clé client	Unique, NOT NULL
date_inscription	Date de création du compte	DATE	–	–	Temporel	≤ date du jour

Table : employé


Colonne	Description	Type	Clé	Longueur	Nature	Règle
id_employe	Identifiant unique employé	VARCHAR VARCHAR	PK	200	Clé employé	Unique, NOT NULL
employe	Nom complet affiché	VARCHAR	–	200	Descriptive	Concaténation prénom + nom
prenom	Prénom de l'employé	VARCHAR	–	100	Personne	Majuscule initiale
nom	Nom de famille	VARCHAR	–	100	Personne	Tout en majuscules

Table : calendrier

Colonne	Description	Type	Clé	Longueur	Nature	Règle
date	Date civile	DATE	PK	–	Temporel	Unique, NOT NULL
annee	Année	INTEGER	–	4	Temporel dérivé	YEAR(date)
mois	Mois (1-12)	INTEGER	–	2	Temporel dérivé	1 à 12
jour	Jour du mois	INTEGER	–	2	Temporel dérivé	1 à 31
mois_nom	Nom du mois	VARCHAR	–	20	Descriptive	Français (ex : Août)
annee_mois	Clé YYYY-MM	VARCHAR	–	7	Dérivé	Format YYYY-MM
jour_semaine	Jour de la semaine	VARCHAR	–	15	Dérivé	Ex : Lundi
trimestre	Trimestre	VARCHAR	–	4	Dérivé	Q1, Q2, Q3 ou Q4

Analyse de la base de données

Schéma relationnel





Présentation du prototype de BDD

Explication de la base de données


Création de la BDD en SQLITE

```
# 5. Table Vente_detail
db.execute_sql("""
CREATE TABLE IF NOT EXISTS Vente_detail (
    id_bdd VARCHAR(200) PRIMARY KEY,
    customer_id VARCHAR(50) NOT NULL,
    id_employe INTEGER,
    ean CHAR(13) NOT NULL,
    date_achat INTEGER NOT NULL,
    id_ticket VARCHAR(50),
    FOREIGN KEY (customer_id) REFERENCES
Clients(customer_id),
    FOREIGN KEY (id_employe) REFERENCES
Employe(id_employe),
    FOREIGN KEY (ean) REFERENCES Produit(ean)
);
""")
```


Insertion des données via Pandas

```
# 5 Insertion Vente_detail
dfVente = pd.read_csv("data/Vente_Detail.csv")
# Renommer les colonnes pour correspondre à la BDD
dfVente.rename(columns={
    "ID_BDD": "id_bdd",
    "CUSTOMER_ID": "customer_id",
    "id_employe": "id_employe",
    "EAN": "ean",
    "Date achat": "date_achat",
    "ID ticket": "id_ticket"
}, inplace=True)
dfVente['date_achat'] =
pd.to_datetime(dfVente['date_achat'],
origin='1899-12-30', unit='D')
db.execute_sql("DELETE FROM Vente_detail")
dfVente.to_sql("Vente_detail", conn,
if_exists='append', index=False)
print("Données Vente_detail insérées.")
```

Vérification de l'importation avec SQLite Viewer



SQLite Viewer
view sqlite file online

Drop file here to load content or click on this box to open file dialog.

Vente_detail (41377 rows) Export

SELECT * FROM 'Vente_detail' LIMIT 0,30 Execute

id_bdd	customer_id	id_employe	ean	date_achat	id_ticket
HZDG8U15NNY7S16HDK8NMFDEK...	CUST-G42Z6WE8QLWJ	b413ca065a762e8cf2e86cea8b9c174	6473630445822	2024-08-14 00:00:00	t_2693
1H51BR800TK9DCIH8M9QCRH3LE...	CUST-CUA37GP8GABQ	a7ada0770091e838e3dcd45265282...	1857802002765	2024-08-14 00:00:00	t_4408
W6VNWK6ZX0D4QZ545ZD5Y0THW...	CUST-NHWI0DGNESYI	fa836e3f5faf72d24e079235332169ce	6831886714876	2024-08-14 00:00:00	t_3258
58EC3JD1TDZZAVQZAW4AHFOUEK...	CUST-IYXDMN7Q11O4	6c1c3292c852c6c593b95cc146b00c...	6916826750723	2024-08-14 00:00:00	t_1080
96FE6HA918RDDF6XRI3O9B83M5P...	CUST-VR9O54A46EVF	38680e129f45c49322cb12303b7fb6...	7930902861368	2024-08-14 00:00:00	t_979
SFJTXQMU24K7K8LFB3VKOK6A3GQ...	CUST-VR9O54A46EVF	38680e129f45c49322cb12303b7fb6...	1107570796338	2024-08-14 00:00:00	t_979
OYCXHDF930OC6IT7A3ZC842J7C50...	CUST-VR9O54A46EVF	38680e129f45c49322cb12303b7fb6...	3300979065063	2024-08-14 00:00:00	t_979
GU0P1HRGOYVWH6CZ3JOMMLTOE7...	CUST-0Q6DPH2HT4D4	b5a8777821fdab1a20a4bc0e5f98dfa0	7189964709179	2024-08-14 00:00:00	t_4245
XOVNXYKA0VY2FT9NLC7O5EOV8Q...	CUST-Y5PASK3M43ER	578b43483938010803dcdf457753d...	8611110524962	2024-08-14 00:00:00	t_3929
1S4I6VS4WJ15RHCPS1CGTFMAE12...	CUST-13MHPVC48DMB	6fa61d0ecae0b563fef18d36b2039c8e	8589480061513	2024-08-14 00:00:00	t_4180
7YA8E6QYDEEF97SETMFL6N3SRP1E...	CUST-YFHO3R4XPYQR	658e6925c1774feb2781a2888c9d42...	9491721740592	2024-08-14 00:00:00	t_817
4UY036RR8OQFSQASOZV5IFL9NQY...	CUST-FB406E19DXG1	c36c4a024dd3bbe72042482e25923...	9054957126839	2024-08-14 00:00:00	t_4289



Résultat des requêtes SQL

Le chiffre d'affaires total pour le 14 Août 2024

```
req1 = db.select_sql("""
    SELECT SUM(p.prix) AS chiffre_affaires_total
    FROM Produit p
    JOIN Vente_detail v ON v.ean = p.ean
    WHERE v.date_achat = (
        SELECT date
        FROM Calendrier
        WHERE annee = 2024
        AND mois = 8
        AND jour = 14)
    """)
```



284243.88

Résultat des requêtes SQL

Le chiffre d'affaires par client pour le top 10 des clients

```
req2 = db.select_sql("""
    SELECT c.customer_id, SUM(p.prix) AS chiffre_affaires_total
    FROM Produit p
    JOIN Vente_detail v ON v.ean = p.ean
    JOIN Clients c ON c.customer_id = v.customer_id
    GROUP BY c.customer_id
    ORDER BY chiffre_affaires_total DESC
    LIMIT 10;
""")
```



```
('CUST-JNSOZSFORR88', 846.86),
('CUST-GM6VBAYAB8SF', 666.86),
('CUST-L2ST2JHI7K9O', 644.18),
('CUST-WU7ZKQJE4L17', 608.93),
('CUST-9WM83101QDTI', 582.03),
('CUST-ZMAOVX8XYGJY', 576.39),
('CUST-3K66CV0OHH7Q', 571.43),
('CUST-CG23SXJDRNYR', 531.09),
('CUST-D8IOFHVUF3Y', 477.35),
('CUST-IHN1HQRI7PYJ', 463.73)
```



Résultat des requêtes SQL

Le chiffre d'affaires encaissé par employé

```
req2 = db.select_sql("""
    SELECT e.employe, SUM(p.prix) AS
chiffre_affaires_total
    FROM Produit p
    JOIN Vente_detail v ON v.ean = p.ean
    JOIN Employe e ON e.id_employe = v.id_employe
    GROUP BY e.id_employe
    ORDER BY chiffre_affaires_total DESC
    LIMIT 10;
""")
```



('aboulet', 7818.82),
('ejacquier', 7736.16),
('cdelisle', 6995.14),
('pmanoury', 6616.46),
('tarsenault', 6483.84),
('adufresne', 6361.22),
('adutertre', 6133.34),
('pange', 6112.37),
('alièvremont', 6111.18),
('prodier', 6094.62)



Analyse des logs

Dictionnaire des données et explications

Structure des colonnes du fichier Logs.xlsx

Colonne	Signification	Exemple de valeur
id_user	Identifiant unique de l'utilisateur (hashé)	08c8b678f8e6f0caz05880ef4ebba10az ← utilisateur système / admin
date	Date au format nombre Excel	45518 → 14 août 2024`
action	Type d'opération réalisée	INSERT, UPDATE, DELETE
table_insert	Table cible de l'opération	Ventes, Produits, Client, Employé
id_ligne	Identifiant de l'enregistrement concerné	CUST-XXXXX..., EAN 13 chiffres, ou t_3960
champs	Nom du champ modifié	prix, hash_mdp, date_inscription, etc.
detail	Nouvelle valeur appliquée	2.54, 2024-08-02 00:00:00, a1b2c3d4...
Unnamed: 7	Colonne vide (résidu Excel)	Toujours vide ou 0.0

Compréhension des problèmes sur la base des logs

- Analyse Logs.xlsx (207 489 lignes)
- Répartition actions : INSERT (206 905), UPDATE (582), DELETE (2)
- **2 dates :**
 - 45518 (14 août 2024) : INSERT (200 010), UPDATE (582), DELETE (2)
 - 45519 (15 août 2024) : INSERT (6895) -> uniquement sur la table "Ventes"
- Chaque ligne du log liée à l'action 'insert_ventes' correspond à l'insertion d'une seule donnée sur un champ précis. Pour insérer une ligne complète dans la table 'Vente_detail', il faut 5 valeurs (voir image ci-dessous).
- Découvertes :
 - 575 UPDATE Produits : certaines 'detail' = dates (ex: '2024-08-02') au lieu de décimaux → rejetées (champ prix DECIMAL)
 - 7 UPDATE Employé (hash_mdp) : non appliqués → risque sécurité
 - 2 DELETE Employé : non traçables mais n'existe plus dans la BDD
- Utilisateur suspect : '08c8b678f8e6f0caz05880ef4ebba10az' (système, non lié à Employé), à l'origine de toutes les modifications de prix

	id_user	date	action	table_insert	id_ligne	champs	detail	Unnamed: 7
0	08c8b678f8e6f0caz05880ef4ebba10az	45518	INSERT	Ventes	000MDBR8LMMFI8BWFEYR4KEE8MYGUPJVPEO	CUSTOMER_ID	CUST-F6TIGKY2H6WR	0.0
1	08c8b678f8e6f0caz05880ef4ebba10az	45518	INSERT	Ventes	000MDBR8LMMFI8BWFEYR4KEE8MYGUPJVPEO	id_employe	4853b03deab973a1a8e466025bce5b52	0.0
2	08c8b678f8e6f0caz05880ef4ebba10az	45518	INSERT	Ventes	000MDBR8LMMFI8BWFEYR4KEE8MYGUPJVPEO	EAN	1987784879907	0.0
3	08c8b678f8e6f0caz05880ef4ebba10az	45518	INSERT	Ventes	000MDBR8LMMFI8BWFEYR4KEE8MYGUPJVPEO	Date	45518	0.0
4	08c8b678f8e6f0caz05880ef4ebba10az	45518	INSERT	Ventes	000MDBR8LMMFI8BWFEYR4KEE8MYGUPJVPEO	ID ticket	t_3839	0.0

Problème 1

D'où vient la différence des 9057,29 € ?

Nous savons que des manipulations ont été faites sur 2 jours, le 14 et le 15 Août 2024.
On commence l'investigation du 15 Août

```
# df du 15 août 2025
countDate15aout = dfLog[dfLog['date'] == 45519]
countDate15aout['action'].value_counts()
```

action
INSERT 6895
Name: count, dtype: int64

```
# on vérifie le/les tables en relation avec l'action INSERT
countDate15aout['table_insert'][countDate15aout['action'] == 'INSERT'].value_counts()
```

table_insert
Ventes 6895
Name: count, dtype: int64

Conclusion : le 15 août, seulement l'action **INSERT** et uniquement sur la table **Ventes** ont été effectués

```
# reconstitution des lignes de ventes
dfInsertvente =
countDate15aout.pivot_table(index="id_ligne",
                               columns="champs",
                               values="detail",
                               aggfunc="first").reset_index()
```

champs	id_ligne	CUSTOMER_ID	Date	EAN	ID ticket	id_employe
0	02KPN2CABZGY8JRCE7LM7XA8RWSPXJQ4PV	CUST-B8W3YSU9HIUX	45518	6386228298857	t_2383	951e47dfa4c5298382d1b7d750b0b6a2
1	031Z15H20FGQUWW03LKW7LVMS7HKWNQDLD3	CUST-JVYY8X387IQC	45518	3071133780335	t_1269	faa8bfc560cae9451761b38ff37e6ee9
2	03YMKN1VHPC6MJDWZGSF5V9UST837NIAB2G	CUST-D75J7MXVCWER	45518	8343814574434	t_3960	342281771d02d2096972e38e78e7d6bd
3	04QJ0DLN36KKK59993GOIN4DJAY7R9V5OVR	CUST-LDTNLBJTV3PN	45518	971146716604	t_1059	1c1d83678cc463b52366dae07cd14c8a
4	04TMH0A87ZIED7S0G3D0TMM6JGY3LLYKBY7	CUST-QBACW9YNWP81	45518	6581057921428	t_2696	6d0cd9c04db768e471c92be478c88a32

```
# ajout des produits
dfProduits = pd.read_csv("data/Produits.csv")
dfProduitsClean = dfProduits[["EAN", "Libelle_produit", "prix"]]
dfFinal15aout = dfInsertvente.merge(dfProduitsClean, on="EAN", how="left")
```

	id_ligne	CUSTOMER_ID	Date	EAN	ID ticket	id_employe	Libelle_produit	prix
0	02KPN2CABZGY8JRCE7LM7XA8RWSPXJQ4PV	CUST-B8W3YSU9HIUX	45518	6386228298857	t_2383	951e47dfa4c5298382d1b7d750b0b6a2	plet blc dce frce 1.2kg pf	4.00
1	031Z15H20FGQUWW03LKW7LVMS7HKWNQDLD3	CUST-JVYY8X387IQC	45518	3071133780335	t_1269	faa8bfc560cae9451761b38ff37e6ee9	250gboulgur quino sesam doy bj	1.85
2	03YMKN1VHPC6MJDWZGSF5V9UST837NIAB2G	CUST-D75J7MXVCWER	45518	8343814574434	t_3960	342281771d02d2096972e38e78e7d6bd	mixa huile dche repar 400 ml	3.95
3	04QJ0DLN36KKK59993GOIN4DJAY7R9V5OVR	CUST-LDTNLBJTV3PN	45518	971146716604	t_1059	1c1d83678cc463b52366dae07cd14c8a	panier rect soft gris pm	4.99
4	04TMH0A87ZIED7S0G3D0TMM6JGY3LLYKBY7	CUST-QBACW9YNWP81	45518	6581057921428	t_2696	6d0cd9c04db768e471c92be478c88a32	veau marengo et pates 300g mar	4.87

```
# somme des prix le 15 août
dfFinal15aout["prix"].sum()
```

np.float64 (9057.29)

La différence du CA vient de l'ajout sur les ventes effectuée le 15 Août 2024

Vérification supplémentaire

Analyse du 14 Août 2024 sur les ajouts des ventes

```
countDate14aout = dfLog[dfLog['date'] == 45518]
df15aout = countDate14aout[(countDate14aout['action'] == 'INSERT') & (countDate14aout['table_insert'] == 'Ventes')]
dfInsertvente14aout = df15aout.pivot_table(index="id_ligne",
                                             columns="champs",
                                             values="detail",
                                             aggfunc="first").reset_index()
dfFinal14aout = dfInsertvente14aout.merge(dfProduitsClean, on="EAN", how="left")
```

```
# on vérifie la somme au 14 Août
dfFinal14aout["prix"].sum()
```

np.float64(275186.58999999997)


chiffre d'affaire

14 août	15 août	16 août
275 168, 59	9 057,29	284 243,88 (275 168, 59 + 9 057,29)

Problème 2


Variation sur le chiffre d'affaires

#	Erreurs trouvées	Impact sur la variation
1	Mise à jour des produits, erreur de typage : dates au lieu de décimaux	Aucun : même si les mise à jour échouent, les anciens prix resteraient en place dans la table Produit. Le CA sera toujours calculable
2	Mise à jour des mots de passe des employés	Aucun : ne modifie pas les prix des produits ni les lignes de vente, donc aucune influence sur le chiffre d'affaires
3	Suppression des employés	Aucun : ne modifie pas non plus les prix des produits



Problème lié au MCD

- Le calcul du chiffre d'affaires utilise les prix de la table Produit.
- Toute modification ou suppression d'un prix dans cette table impacte rétroactivement les ventes passées et donc le CA.



Solution proposée

Ajouter le champ prix_produit directement dans la table Vente_detail.

Avantages :

- Le prix facturé est figé au moment de la vente → fin des variations rétroactives du CA.
- Le calcul du chiffre d'affaires s'effectue uniquement sur la table Vente_detail (plus besoin de jointure avec Produit).
- Requêtes plus simples, plus rapides et moins coûteuses en ressources.



Recommandations pour l'entreprise

Avantages et inconvénients de la solution

Planning de mise en place et coût éventuel

Priorité	Recommandation	Justification (liée SCD / OLAP / fiabilité)
Haute	Ajouter le champ prix_produit DECIMAL(10,2) dans la table Vente_detail.	Figé le prix facturé au moment de la vente (rend le fait immuable), évitant les réécritures rétroactives du CA dues aux updates dans Produits.
Haute	Créer une table Produits_Historique liée à Produit et Utilisateur pour traçabilité complète.	Implémente SCD Type 2/4 pour conserver l'historique des prix sans impacter les faits passés. Permet d'analyser l'impact des changements sur le CA.
Haute	Valider strictement les types avant UPDATE prix (rejet des dates dans DECIMAL).	Prévient les échecs silencieux d'updates (typage incorrect), cause racine des incohérences observées.
Haute	Architecture anti-surcharge & haute disponibilité : • Déploiement du pipeline ETL sur le cloud (AWS/GCP/Azure) avec auto-scaling (Kubernetes, etc.). • Ou mise en place d'un 2e serveur / instance de traitement dédiée aux batches en cas de pic	Explication de la perte des ventes du 14 août : le serveur unique était saturé → certaines transactions/insertions ont été droppées silencieusement. Le cloud + scaling ou une machine dédiée évite ce scénario catastrophique.
Moyenne	Alerte Slack/mail sur UPDATE rejeté ou anomalie détectée. Créer un environnement de staging (copie quotidienne). Documentation officielle + MCD à jour + audit mensuel automatisé des logs.	Améliore la réactivité et la prévention. Staging pour tests sans risque. Doc pour onboarding.
Moyenne	Implémenter un processus ETL automatisé pour détecter et gérer les changements (ex. : hashing des colonnes prix, CDC pour real-time si possible).	Automatise la gestion SCD (détection changes via hash ou CDC), évitant les scripts manuels défectueux.
Basse	Monitorer les performances post-SCD (stockage, temps queries) et former l'équipe sur les bonnes pratiques SCD	Type 2 fait grossir les tables → il faut surveiller les perfs. La formation évite les récidives humaines.

Conclusion

Le 14 août 2024, le chiffre d'affaires réel et définitif est bien 275 186,59 € (prix d'origine).

La variation de +9 057,29 € observée entre le 14 et le 16 août n'est pas une erreur Power BI, mais la conséquence directe d'une modification des prix dans la table Produit après la clôture de la journée. Comme le prix n'est pas historisé dans les lignes de vente, toute modification du catalogue réécrit l'histoire du chiffre d'affaires.

La variation sur le CA est la conséquence directe d'un défaut d'architecture du MCD car le calcul du CA repose sur le prix courant de la table Produit.

