



Anticipez les besoins en consommation de bâtiments

Contexte

Prédire la consommation énergétique des bâtiments non résidentiels

Objectif

Comprendre la structure des données

Nettoyer les données (nulls, outliers, incohérences)

Feature Engineering (ajout de données pertinentes)


Préparation des features pour la modélisation

Comparaison de différents modèles supervisés

Optimisation du modèle

Analyse Exploratoire des Données

Nettoyage des Données - Suppression des lignes



Incohérences
2016 < YearBuilt < 1900
NumberofBuildings = 0

1492

1477

Outliers
Outliers > 99e percentile sur
SiteEnergyUse(kBtu) → environ 1%
des données



1546

Filtrage NonResidential
Environ 43 % sont classés comme
"NonResidential"

1544

Drop nulls

Très peu de bâtiments ont des
valeurs manquantes avec une
perte de seulement 2 lignes

Analyse Exploratoire des Données

Nettoyage des Données - Suppression des colonnes

Identifiants

OSEBuildingID, PropertyName, Address, TaxParcelIdentificationNumber

Localisation précise

Latitude, Longitude, ZipCode - redondant avec Neighborhood

Colonnes dérivées de la cible

Electricity(kBtu), NaturalGas(kBtu), etc...

Colonnes avec trop de nulls

Comments, Outlier, YearsENERGYSTARCertified

Colonnes constantes

DataYear : toutes les lignes ont la valeur 2016, City : Seattle, Stat : WA, ect...

Analyse Exploratoire des Données

Statistiques Descriptives & Insights Clés


Variable	Moyenne	Médiane	Min	Max	Insight clé
YearBuilt	1960.8	1965	1900	2015	Beaucoup de bâtiments anciens
PropertyGFATotal	105 492 sq ft (~9 800 m ²)	46 879 sq ft (~4 360 m ²)	16 300 sq ft (~1 515 m ²)	1 605 578 sq ft (~149 200 m ²)	Forte dispersion (quelques très grands)
SiteEnergyUse(kBtu)	6,22 M kBtu	2,53 M kBtu	0	65,05 M kBtu	Distribution très asymétrique (skewed)
ENERGYSTARScore	66.32	71	1	100	Score médian moyen → potentiel d'amélioration

Analyse Exploratoire des Données

Visualisations




Matrice de corrélations



- Forte corrélation entre **PropertyGFATotal** et **SiteEnergyUse(kBtu)** : $r = 0.73$
- Très forte corrélation entre **PropertyGFATotal** et **PropertyGFABuilding(s)** : $r = 0.97$
- **NumberOfFloors** corrélé à la consommation ($r = 0.52$) et à la surface ($r = 0.67$)
- **ENERGYSTARScore** corrélé très faiblement à la consommation ($r = -0.019$) → pas un prédicteur fort seul
- **ZipCode** et **CouncilDistrictCode** : corrélations faibles → localisation a un impact limité linéairement




Distribution de la consommation



- Distribution fortement **asymétrique à droite**
- Beaucoup de bâtiments à faible consommation ($< 2\text{M kBtu}$)
- Quelques bâtiments très énergivores ($> 5\text{M kBtu}$)


Analyse Exploratoire des Données

Visualisations



Surface vs Consommation

- **Relation linéaire positive claire** : plus la surface augmente, plus la consommation augmente



Consommation par type de bâtiment

- **Laboratories et Hospitals** : consommations médianes très élevées (médiane > 4M kBtu)
- **Hotels, Large Offices, Universities** : médianes élevées (~1-2M kBtu)
- **Small Offices, Warehouses, Low-Rise Multifamily** : consommations basses

Modélisation

Feature Engineering – Préparation des Données



Objectifs : Améliorer la qualité des features pour la modélisation.

Création de nouvelles features

- **Age du bâtiment (BuildingAge)** : Calculé comme $2016 - \text{YearBuilt}$ (année des données) pour capturer l'impact de l'âge sur l'efficacité énergétique
- **Features dérivées de surfaces** :
 - $\text{Ratio ParkingRatio} = \text{PropertyGFAParking} / \text{PropertyGFATotal}$ pour évaluer l'influence du parking.
 - $\text{Ratio surface par étage} = \text{PropertyGFATotal} / \text{NumberofFloors}$

Traitement des distributions

- **Normalisation/Standardisation** des features numériques (PropertyGFATotal, NumberofFloors) via **StandardScaler**.
- **Transformation** des valeurs catégorielles en variables numérique via **One-Hot Encoding**

Modélisation

Comparaison des Modèles



Objectifs : Évaluer les performances des différents modèles pour prédire la consommation énergétique totale

Modèle	CV R ² (5-fold) mean ± std	Test R ²	Test MAE (kBtu)	Test RMSE (kBtu)
Dummy (moyenne)	-0.002 ± 0.003	-0.002	5 886 910	9 118 007
Régression Linéaire	0.557 ± 0.119	0.637	3 037 272	5 489 842
Random Forest	0.617 ± 0.083	0.625	2 768 851	5 576 929
Gradient Boosting	0.590 ± 0.092	0.647	2 814 434	5 416 267
SVR	-0.145 ± 0.018	-0.134	4 720 387	9 700 873

Modélisation

Optimisation et Interprétation du Modèle



Objectifs : Optimiser le **Gradient Boosting** avec **GridSearchCV** pour améliorer la prédiction de la consommation énergétique (SiteEnergyUse(kBtu))

Optimisation des hyperparamètres

```
# Meilleurs paramètres trouvés
{
  'model__learning_rate': 0.1,
  'model__max_depth': 5,
  'model__min_samples_split': 7,
  'model__n_estimators': 50,
  'model__subsample': 0.8
}
```



Performances obtenues

Métrique	Avant optimisation	Après optimisation
CV R ² (meilleur)	0.590 ± 0.092	0.623
Test R ²	0.647	0.611
Test RMSE (approx.)	~5.42 M kBtu	Légèrement moins bon

Modélisation

Identifier les features les plus impactantes

Permutation Importance de sklearn

Top 15 Features les plus importantes (Gradient Boosting)

