

Construisez et testez une infrastructure de données

Sophana SEAN - Janvier 2026





CONTEXTE

La société GreenCorp cherche à améliorer les algorithmes de prévision météorologiques.

En tant que Data Engineer, je dois mettre en place une pipeline fiable.

OBJECTIFS

- Récupérer et transformer les données
- Sécurisation et migration des données vers MongoDB
- Conteneurisation avec Docker
- Déploiement sur AWS

1. Récupérer et transformer les données



Source : **Data_Source1_011024-071024.json**

```
status: "OK"
errors: []
data: []
stations: (4) [ {}, {}, {}, {} ]
metadata: { temperature: "temperature,degC", pression: "mean sea level pressure,hPa", humidite: "relative humidity,%" , _ : }
hourly: { 07015: (60) [ ... ], 00052: (361) [ ... ], 000R5: (361) [ ... ], _ : }
```



Suppression des clés inutiles : **status, errors, data et metadata**



Imbrication des données : **ajout de la clé "hourly" dans "stations" via id_station dans hourly**



Ajout de 2 stations amateurs : **La Madeleine (FR) & Ichtegem (BE)**



1. Récupérer et transformer les données

Transformations appliquées sur chaque ligne

- Nettoyage des valeurs textes avec unités en nombre (°F, mph, inHg, in, %, etc.)
- Conversions systématiques :
 - °F → °C
 - mph → m/s (vent moyen & rafales)
 - inHg → hPa (pression)
 - inches → mm (pluie)
- Ajout des champs manquants (visibilite, neige_au_sol, nebulosite, temps_omm) → None
- Création d'un timestamp complet dh_utc (date fixe 2024-10-05 + heure de la colonne Time)



1. Récupérer et transformer les données

Schéma de la base de données

Structure d'un enregistrement horaire

```
{
  "dh_utc":      "2024-10-05 14:30:00",
  "temperature": 13.4,           // °C
  "point_de_rose": 10.2,        // °C
  "humidite":    87,             // %
  "vent_direction": "WSW",      // ou null
  "vent_moyen":  2.1,           // m/s
  "vent_rafales": 4.8,          // m/s
  "pression":    998.2,         // hPa
  "pluie_1h":    0.0,           // mm
  "pluie_3h":    2.3,           // mm
  "uv":          1,             // index UV
  "solar":       145.0,         // W/m²
  "visibilite":  null,
  "neige_au_sol": null,
  "nebulosite":  null,
  "temps_omm":   null
}
```

Schéma final de la bdd

```
"stations": [
{
  "id": "00052",
  "name": "Armentières",
  "latitude": 50.689,
  "longitude": 2.877,
  "elevation": 16,
  "type": "static",
  "license": {
    "license": "CC BY",
    "url": "https://creativecommons.org/licenses/by/2.0/fr/",
    "source": "infoclimat.fr",
    "metadonnees": "https://www.infoclimat.fr/stations/metadonnees.php?id=00052"
  },
  "hourly": [
    {
      "dh_utc": "2024-10-05 00:00:00",
      "temperature": 6.4,
      "pression": 1019.1,
      "humidite": 95,
      "point_de_rose": 5.6,
      "visibilite": null,
      "vent_moyen": 0.0,
      "vent_rafales": null,
      "vent_direction": 134,
      "pluie_1h": 0.0,
      "pluie_3h": 0.0,
      "neige_au_sol": null,
      "nebulosite": null,
      "temps_omm": null
    }
  ]
}
]
```

2. Sécurisation et migration des données vers MongoDB

Logigramme du processus de sécurisation

1. Charge le fichier consolidé stations_final.json
2. Vérifie rigoureusement l'intégrité et la qualité des données
3. Si toutes les vérifications passent → migre les données vers MongoDB
4. Produit un rapport qualité avant et après migration


Points clés du contrôle qualité (pré-migration)

- Champs station obligatoires : `id`, `name`, `latitude`, `longitude`, `elevation`, `type`, `license`, `hourly`
- Champs attendus dans chaque relevé horaire (tous obligatoires dans le contrôle) :
 - `dh_utc`, `temperature`, `pression`, `humidite`, `point_de_rose`, `visibilite`, `vent_moyen`, `vent_rafales`,
`vent_direction`, `pluie_1h`, `pluie_3h`, `neige_au_sol`, `nebulosite`, `temps_omm`
- Contrôles renforcés sur les 3 champs critiques : `temperature`, `pression`, `humidite` → doivent être numériques et non-None
- Détection stricte des doublons sur `dh_utc` par station

Règle importante :


La migration n'est lancée **que si TOUTES les stations passent 100% des contrôles**.

Si non → message d'erreur clair et migration annulée.



3. Conteneurisation avec Docker

Schéma de l'architecture de la base de données



Déploiement Docker

Arborescence

```
project/
|
├─ docker-compose.yml
├─ Dockerfile
├─ migration.py
├─ stations_final.json
├─ requirements.txt
└─ reports/
```

Dockerfile

```
FROM python:3.13-slim

WORKDIR /app

COPY requirements.txt .
RUN pip install --no-cache-dir -r requirements.txt

COPY migration.py .
COPY stations_final.json .

CMD ["python", "migration.py"]
```

docker-compose.yml

```
version: "3.9"


services:
  mongodb:
    image: mongo:7
    container_name: mongodb
    ports:
      - "27017:27017"
    volumes:
      - mongo_data:/data/db

  migration:
    build: .
    container_name: migration
    depends_on:
      - mongodb
    environment:
      - MONGO_URI=mongodb://mongodb:27017
    command: python migration.py

volumes:
  mongo_data:
```

3. Conteneurisation avec Docker

Résultat Docker Desktop



The screenshot shows the Docker Desktop interface. The left sidebar contains navigation options: Ask Gordon (BETA), Containers, Images, Volumes, Kubernetes, Builds, Models, MCP Toolkit (BETA), Docker Hub, Docker Scout, and Extensions. The main panel displays the 'migration-stations' container, which is in an 'Exited' state (0 days ago). The 'Logs' tab is selected, showing the following output:

```
Attente de MongoDB...
MongoDB prêt ! Lancement de la migration...

==== RAPPORT QUALITÉ POST-MIGRATION ====
==== Intégrité des données ===
==== Vérification : Champs obligatoires - Données horaires présentes/manquantes - Doublons ===
✓ Station Armentières : toutes les données sont correctes !
✓ Station Bergues : toutes les données sont correctes !
✓ Station Lille-Lesquin : toutes les données sont correctes !
✓ Station Hazebrouck : toutes les données sont correctes !
✓ Station La Madeleine : toutes les données sont correctes !
✓ Station WeerstationBS : toutes les données sont correctes !

==== RAPPORT QUALITÉ POST-MIGRATION ====
Nombre de stations insérées      : 6
Nombre total de relevés horaires : 1719

Taux de complétude des champs critiques :
• temperature → 100.0% complété ( 0 valeurs manquantes)
• pression    → 100.0% complété ( 0 valeurs manquantes)
• humidite    → 100.0% complété ( 0 valeurs manquantes)
• point_de_rosee → 100.0% complété ( 0 valeurs manquantes)
• vent_moyen  → 100.0% complété ( 0 valeurs manquantes)
• vent_rafales → 37.0% complété (1083 valeurs manquantes)
• pluie_1h    → 100.0% complété ( 0 valeurs manquantes)
```

The bottom status bar indicates the engine is running, with system metrics: RAM 8.32 GB, CPU 3.63%, and Disk 34.65 GB used (limit 1006.85 GB). An 'Update available' notification is present in the bottom right corner.

4. Déploiement sur AWS



4. Déploiement sur AWS

Migration sur ESC mongoDB

migration.py

```
if status == True:
    MONGO_URI = os.getenv("MONGO_URI", "mongodb://18.234.207.25:27017")
    client = MongoClient(MONGO_URI)
    db = client["greenandcoop"]
    collection = db["stations"]
```

```
==== Intégrité des données ====
==== Vérification : Champs obligatoires - Données horaires présentes/manquantes - Doublons ====
✓ Station Armentières : toutes les données sont correctes !
✓ Station Bergues : toutes les données sont correctes !
✓ Station Lille-Lesquin : toutes les données sont correctes !
✓ Station Hazebrouck : toutes les données sont correctes !
✓ Station La Madeleine : toutes les données sont correctes !
✓ Station WeerstationBS : toutes les données sont correctes !
```

```
==== RAPPORT QUALITÉ POST-MIGRATION ====
Nombre de stations insérées : 6
Nombre total de relevés horaires : 1719
```

```
Taux de complétude des champs critiques :
• temperature → 100.0% complété ( 0 valeurs manquantes)
• humidite → 100.0% complété ( 0 valeurs manquantes)
• point_de_rose → 100.0% complété ( 0 valeurs manquantes)
• vent_rafales → 37.0% complété (1083 valeurs manquantes)
• pluie_1h → 100.0% complété ( 0 valeurs manquantes)
```

Vérification Compass

AWS > greenandcoop > stations

Documents 6 Aggregations Schema Indexes 1 Validation

Type a query: { field: 'value' } or [Generate query](#)

ADD DATA UPDATE DELETE EXPORT DATA EXPORT CODE

```
{
  name: "Bergues"
  latitude: 50.968
  longitude: 2.441
  elevation: 17
  type: "static"
  license: Object
  hourly: Array (361)
```

```
_id: ObjectId('6979069f2025115de40833d2')
id: "07015"
name: "Lille-Lesquin"
latitude: 50.575
longitude: 3.092
elevation: 47
type: "synop"
license: Object
hourly: Array (60)
```

4. Déploiement sur AWS

Reporting sur le temps d'accessibilité des données



reporting.py

```
import time
import csv
from pymongo import MongoClient
from datetime import datetime

client = MongoClient("mongodb://18.234.207.25:27017")
db = client["greenandcoop"]
collection = db["stations"]

query = {
    "name": "Paris-Montsouris",
    "hourly.dh_utc": {
        "$gte": datetime(2025, 1, 15),
        "$lt": datetime(2025, 1, 16)
    }
}

projection = {
    "_id": 0,
    "name": 1,
    "hourly": 1
}

durations = []

for i in range(10):
    start = time.perf_counter()
    result = list(collection.find(query, projection))
    end = time.perf_counter()
    durations.append(end - start)

client.close()
```

Résultat

```
==== REPORTING ACCESSIBILITÉ DONNÉES ====
requete : Météo 15/01/2025 - Paris-Montsouris
nb_executions : 10
temps_min_ms : 93.55
temps_moyen_ms : 135.08
temps_max_ms : 498.73
✓ Reporting exporté dans data/reporting_accessibilite_mongo.csv
PS C:\Users\Phana\Desktop\Formation - Data Engineer\Projet\08 - Construisez et testez une infrastructure de données> python reporting.py

==== REPORTING ACCESSIBILITÉ DONNÉES ====
requete : Météo 15/01/2025 - Paris-Montsouris
nb_executions : 10
temps_min_ms : 87.93
temps_moyen_ms : 126.85
temps_max_ms : 474.43
✓ Reporting exporté dans data/reporting_accessibilite_mongo.csv
PS C:\Users\Phana\Desktop\Formation - Data Engineer\Projet\08 - Construisez et testez une infrastructure de données> |
```



AWS

Rechercher

[Alt+S]

États-Unis (Virginie du Nord)

Seán (5559-1516-1968)

Seán

CloudWatch

Gestion des journaux

/ecs/mongodb-task

ecs/mongodb-container/48e5b869c594588aba840ab9420389

Favoris et récents

Ingestion

Tableaux de bord

Alarmes

Opérations liées à l'IA

GenAI Observability

Signaux d'application (APM)

Infrastructure Monitoring

Journaux

Log Management

Anomalies dans les journaux

Queue en direct

Logs Insights

Contributor Insights

Métriques

Surveillance du réseau

Setup

Événements de journaux

Vous pouvez utiliser la barre de filtre ci-dessous pour rechercher et faire correspondre des termes, des expressions ou des valeurs dans vos événements de journal.

Q Filtrer les événements : appuyez sur Entrée pour rechercher.

Effacer 1m 30m 1h 12h Personnalisées Fuseau horaire UTC Affichage


Horodatage	Message
2026-01-29T17:28:19.370Z	{\"@timestamp\":\"2026-01-29T17:28:19.370+00:00\",\"source\":\"I\", \"category\":\"STORAGE\", \"id\":\"5071100\", \"context\":{\"initandlisten\":\"msg\":\"Clearing temp directory\"}}
2026-01-29T17:28:19.370Z	{\"@timestamp\":\"2026-01-29T17:28:19.370+00:00\",\"source\":\"I\", \"category\":\"STORAGE\", \"id\":\"10682200\", \"context\":{\"initandlisten\":\"msg\":\"Dropping spill ids\",\"attributes\":{\"numDeletes\":0}}}
2026-01-29T17:28:19.370Z	{\"@timestamp\":\"2026-01-29T17:28:19.370+00:00\",\"source\":\"I\", \"category\":\"CONTROL\", \"id\":\"6608200\", \"context\":{\"initandlisten\":\"msg\":\"Initializing cluster server parameters from disk\"}}
2026-01-29T17:28:19.370Z	{\"@timestamp\":\"2026-01-29T17:28:19.370+00:00\",\"source\":\"I\", \"category\":\"CONTROL\", \"id\":\"20536\", \"context\":{\"initandlisten\":\"msg\":\"Flow Control is enabled on this deployment\"}}
2026-01-29T17:28:19.370Z	{\"@timestamp\":\"2026-01-29T17:28:19.370+00:00\",\"source\":\"I\", \"category\":\"FTDC\", \"id\":\"20625\", \"context\":{\"initializing_full_time_diagnostic_data_capture\":\"attributes\":{\"dataDirectory\":\"/data/d...\"}}
2026-01-29T17:28:19.371Z	{\"@timestamp\":\"2026-01-29T17:28:19.371+00:00\",\"source\":\"I\", \"category\":\"STORAGE\", \"id\":\"20320\", \"context\":{\"initandlisten\":\"msg\":\"createCollection\",\"attributes\":{\"namespace\":\"local.startup_log\",\"uid\":{\"disposition\":\"...\"}}
2026-01-29T17:28:19.382Z	{\"@timestamp\":\"2026-01-29T17:28:19.382+00:00\",\"source\":\"I\", \"category\":\"INDEX\", \"id\":\"20345\", \"context\":{\"initandlisten\":\"msg\":\"Index build: done building\",\"attributes\":{\"buildUUID\":\"null\",\"collectionUID\":\"{\\\"uid\\\":(\\\"...\"}}
2026-01-29T17:28:19.382Z	{\"@timestamp\":\"2026-01-29T17:28:19.382+00:00\",\"source\":\"I\", \"category\":\"REPL\", \"id\":\"6015317\", \"context\":{\"initandlisten\":\"msg\":\"Setting new configuration state\",\"attributes\":{\"newState\":\"ConfigReplicationDisabled...\"}}
2026-01-29T17:28:19.382Z	{\"@timestamp\":\"2026-01-29T17:28:19.382+00:00\",\"source\":\"I\", \"category\":\"STORAGE\", \"id\":\"22262\", \"context\":{\"initandlisten\":\"msg\":\"Timestamp monitor starting\"}}
2026-01-29T17:28:19.382Z	{\"@timestamp\":\"2026-01-29T17:28:19.382+00:00\",\"source\":\"I\", \"category\":\"STORAGE\", \"id\":\"7333401\", \"context\":{\"initandlisten\":\"msg\":\"Starting the DiskSpaceMonitor\"}}
2026-01-29T17:28:19.384Z	{\"@timestamp\":\"2026-01-29T17:28:19.384+00:00\",\"source\":\"I\", \"category\":\"STORAGE\", \"id\":\"20320\", \"context\":{\"LogicalSessionCacheRefresh\":\"msg\":\"createCollection\",\"attributes\":{\"namespace\":\"config.system.sessions\",\"...\"}}
2026-01-29T17:28:19.385Z	{\"@timestamp\":\"2026-01-29T17:28:19.385+00:00\",\"source\":\"I\", \"category\":\"CONTROL\", \"id\":\"20712\", \"context\":{\"LogicalSessionCacheResp\":\"msg\":\"Sessions collection is not set up; waiting until next sessions resp...\"}}
2026-01-29T17:28:19.385Z	{\"@timestamp\":\"2026-01-29T17:28:19.385+00:00\",\"source\":\"I\", \"category\":\"NETWORK\", \"id\":\"23015\", \"context\":{\"listener\":\"msg\":\"Listening on\",\"attributes\":{\"address\":\"/tmp/mongodb-27017.sock\"}}
2026-01-29T17:28:19.385Z	{\"@timestamp\":\"2026-01-29T17:28:19.385+00:00\",\"source\":\"I\", \"category\":\"NETWORK\", \"id\":\"23015\", \"context\":{\"listener\":\"msg\":\"Listening on\",\"attributes\":{\"address\":\"fe.0.0.0:27017\"}}
2026-01-29T17:28:19.385Z	{\"@timestamp\":\"2026-01-29T17:28:19.385+00:00\",\"source\":\"I\", \"category\":\"NETWORK\", \"id\":\"23016\", \"context\":{\"listener\":\"msg\":\"Waiting for connections\",\"attributes\":{\"port\":\"27017\",\"ssl\":\"off\"}}}
2026-01-29T17:28:19.385Z	{\"@timestamp\":\"2026-01-29T17:28:19.385+00:00\",\"source\":\"I\", \"category\":\"CONTROL\", \"id\":\"20712\", \"context\":{\"LogicalSessionCacheResp\":\"msg\":\"Sessions collection is not set up; waiting until next sessions resp...\"}}
2026-01-29T17:28:19.403Z	{\"@timestamp\":\"2026-01-29T17:28:19.403+00:00\",\"source\":\"I\", \"category\":\"INDEX\", \"id\":\"20345\", \"context\":{\"LogicalSessionCacheRefresh\":\"msg\":\"Index build: done building\",\"attributes\":{\"buildUUID\":\"null\",\"collectionUID\":\"...\"}}
2026-01-29T17:28:19.403Z	{\"@timestamp\":\"2026-01-29T17:28:19.403+00:00\",\"source\":\"I\", \"category\":\"INDEX\", \"id\":\"20345\", \"context\":{\"LogicalSessionCacheRefresh\":\"msg\":\"Index build: done building\",\"attributes\":{\"buildUUID\":\"null\",\"collectionUID\":\"...\"}}
2026-01-29T17:29:19.362Z	{\"@timestamp\":\"2026-01-29T17:29:19.362+00:00\",\"source\":\"I\", \"category\":\"WATCHPOINT\", \"id\":\"22430\", \"context\":{\"Checkpointner\":\"msg\":\"WiredTiger message\",\"attributes\":{\"message\":{\"ts_sec\":\"1769797759\",\"ts_usec\":\"361983\"},\"t...\"}}

Aucun nouvel événement pour le moment Nouvelle tentative automatique suspendue. Reprendre

Retour en haut de page

5. Airbyte

Lien : <http://localhost:8000/login>



Airbyte

Email


sean.dunhill63@gmail.com

Password

Log in

Création d'une **connections**

sources (JSON)



File (CSV, JSON, Excel, Feather, Parquet)

File (CSV, JSON, Excel, Feather, Parquet) v0.6.0

Settings Connections

Source Settings

Source name

File (CSV, JSON, Excel, Feather, Parquet)

Dataset Name

Weather_Underground_Ichitegem_BE

File Format

excel

Storage Provider

HTTPS: Public Web


Optional fields

URL

https://s3.eu-west-1.amazonaws.com/course-oc-static.com/projects/922_Data+Engineer/922_P8/M

Optional fields

destination (bucket S3)



S3-meteo-json

S3 v1.9.5

Settings Connections

S3-meteo-json

Access Key ID

Secret Access Key

S3 Bucket Name

p8-airbyte-meteo

S3 Bucket Path

data

S3 Bucket Region

eu-west-3

Output Format

JSON Lines: Newline-delimited JSON

Compression

No Compression

Optional fields

5. Airbyte

Amazon S3

Amazon S3 > Compartiments > p8-airbyte-meteo > json/ > Data_Source1_011024-071024/

Amazon S3

- Compartiments
 - Compartiments à usage général
 - Compartiments de répertoires
 - Compartiments de table
 - Compartiments de vecteur
- Gestion des accès et sécurité
 - Points d'accès
 - Points d'accès pour FSx
 - Access Grants
 - Analyseur d'accès IAM
- Gestion du stockage et

Data_Source1_011024-071024/

Objets Propriétés

Objets (2)

Les objets sont les entités fondamentales stockées dans Amazon S3. Vous pouvez utiliser l'inventaire pour gérer leur accord explicite des autorisations. [En savoir plus](#)

Rechercher des objets en fonction du préfixe

☐	Nom	Type
☐	2026_01_13_1768314551740_0.csv	csv
☐	2026_01_13_1768315061847_0.jsonl	jsonl

2026_01_13_1768314551740_0.csv Infos

[Copier l'URI S3](#) [Télécharger](#) [Ouvrir](#) [Actions d'objet](#)

Propriétés Autorisations Versions

Présentation de l'objet

Propriétaire
bffb7e1b735bc1c58dc5f388f149df9b8d286fbee18995762711f2d35e7701

Région AWS
Europe (Paris) eu-west-3

Dernière modification
13 Jan 2026 03:29:11 PM CET

Taille
305.0 Ko

Type
csv

Clé
json/Data_Source1_011024-071024/2026_01_13_1768314551740_0.csv

URI S3
s3://p8-airbyte-meteo/json/Data_Source1_011024-071024/2026_01_13_1768314551740_0.csv

Amazon Resource Name (ARN)
arn:aws:s3::p8-airbyte-meteo/json/Data_Source1_011024-071024/2026_01_13_1768314551740_0.csv

Balise d'entité (Etag)
<b3f2c3bae2b662380dc834057ade9bc5-1>

URL de l'objet
https://p8-airbyte-meteo.s3.eu-west-3.amazonaws.com/json/Data_Source1_011024-071024/2026_01_13_1768314551740_0.csv