

DÉVELOPPEMENT D'UN SYSTÈME RAG D'ÉVÈNEMENTS CULTURELS

Projet Data Engineer – Sophana SEAN



PRÉSENTATION



CONTEXTE

L'entreprise Puls-Events souhaite tester un **assistant intelligent** capable de recommander des événements culturels.

Les données sources proviennent de **OpenAgenda** (événements culturels publics).

Le but est de développer un **Proof of Concept** (POC) basé sur une approche **RAG** (Retrieval-Augmented Generation).

Ce système permettra d'effectuer une recherche sémantique pour proposer des événements pertinents aux utilisateurs




OBJECTIFS

1. Collecter automatiquement les événements via l'API OpenAgenda
2. Transformer du texte en embeddings (Mistral AI)
3. Indexer efficacement les données avec FAISS
4. Tester des requêtes utilisateur réalistes
5. Construire un chatbot RAG capable de recommander des événements




ARCHITECTURE DU PIPELINE RAG

Pipeline RAG Schéma du pipeline RAG



01 - COLLECTE DES DONNÉES



01

Connexion à l'API
publique **OpenAgenda**

02

Récupération des
événements culturels en
français

03

Filtrage des événements
sur les **12 derniers mois**

04

Sélection des villes ciblées :
Clermont-Ferrand, Lyon,
Nantes et Lille

05


Stockage des données
brutes dans un
DataFrame pandas

06

Export final en CSV
events_filtered.csv

02 - CRÉATION DES EMBEDDINGS

La deuxième étape consiste à transformer les événements en vecteurs numériques, appelés **embeddings**, afin de permettre une recherche par similarité sémantique.



03 - INDEXATION AVEC FAISS

La troisième étape consiste à indexer les embeddings dans FAISS afin de permettre une recherche rapide des événements les plus similaires.



Chargement des embeddings
générés



Création d'un index vectoriel
FAISS



Stockage des vecteurs pour une
recherche rapide



Association avec les
métadonnées : titre, ville, date
chunk_id



Sauvegarde de l'index :
events_faiss.index



Sauvegarde des métadonnées :
events_metadata.pkl



```
Batch 39/40
Batch 40/40
✓ Index FAISS créé avec 800 vecteurs
✓ Index FAISS sauvegardé : data/events_faiss.index
✓ Métadonnées sauvegardées : data/events_metadata.pkl
🔥 Indexation terminée
```

04 – TESTER DES REQUÊTES UTILISATEUR

La dernière étape permet de tester le moteur de recherche sémantique avec des requêtes utilisateur afin de vérifier la pertinence des événements retournés.

- Chargement de l'index **FAISS** et des **métadonnées**
- Transformation de la requête utilisateur en embedding
- Recherche des **5 événements les plus proches**
- Affichage des résultats avec :
 - titre
 - ville
 - date
 - mots-clés
 - distance sémantique

```
Requête : exposition culturelle

--- Résultat #1 ---
UID      : 95690456
Titre     : Exposition Pixels Et Poétique
Ville     : Paris
Date      : 2026-03-26 17:00:00
Mots clés : expo, photography, art contemporain
Chunk ID  : 3
Distance  : 0.4770
Texte     : . Les visiteurs profiteront de cette opportunité unique pour tenter de comparer et de comprendre <strong>d
ris Mots clés : expo, photography, art contemporain...


--- Résultat #2 ---
UID      : 19885141
Titre     : Être Au Souffle | Résonances Art-Science - Newimages Festival 2026
Ville     : Paris
Date      : 2026-04-07 07:00:00
Mots clés : art-science, recherche, exposition
Chunk ID  : 3
Distance  : 0.5301
Texte     : . Les installations art-science resteront exposées jusqu'au 18 avril.<br>Découvrez ci-dessous le programme

--- Résultat #3 ---
UID      : 80687820
Titre     : Close-Up: Art Autour De L'Exposition Pixels Et Poétique
Ville     : Paris
Date      : 2026-03-27 18:00:00
Mots clés : photographie, conférence, exposition, Pixels et poétique
Chunk ID  : 0
Distance  : 0.5356
Texte     : Close-Up: Art Autour De L'Exposition Pixels Et Poétique Découvrez les coulisses des œuvres de Jaroslav Fun
nale de Prague. <p>A l'occasion de l'exposition <a href="https://paris.czechcentres...
```



05 - CONSTRUIRE UN CHATBOT AVEC FLASK

La dernière étape consiste à intégrer le moteur RAG dans une application Flask afin de proposer un chatbot capable de répondre aux utilisateurs à partir des événements indexés.



VALIDATION FONCTIONNELLE

Vérifier le bon fonctionnement du pipeline RAG avant son intégration dans le chatbot

Validation du nettoyage des données avec Pytest

Suppression des doublons (uid)
Vérification des descriptions vides
Contrôle des dates des événements
Normalisation des titres et textes
Vérification des colonnes finales
Validation du format des dates
Vérification de la création des chunks
Contrôle de la génération des embeddings
Validation des fichiers générés

Validation de l'environnement

Vérification des dépendances Python
(pandas - faiss - langchain - mistralai - pytest)

Vérification du chargement du fichier .env

```
✓ numpy OK
✓ pandas OK
✓ requests OK
✓ dotenv OK
✓ langchain OK
✓ langchain_core OK
✓ langchain_community OK
✓ faiss OK
✓ mistralai OK
✓ sentence_transformers OK
✓ pytest OK
✓ .env fonctionne !
```

Ces tests sont automatisés avec Pytest

```
test_clean_events.py::test_clean_removes_duplicates_on_uid PASSED [ 27%]
test_clean_events.py::test_clean_title_and_text_normalization PASSED [ 36%]
test_clean_events.py::test_clean_no_empty_strings PASSED [ 45%]
test_clean_events.py::test_clean_output_columns PASSED [ 54%]
test_clean_events.py::test_clean_keywords_conversion PASSED [ 63%]
test_clean_events.py::test_clean_description_fusion_length PASSED [ 72%]
test_clean_events.py::test_clean_text_for_embedding PASSED [ 81%]
test_clean_events.py::test_clean_no_none_in_text_columns PASSED [ 90%]
test_clean_events.py::test_clean_firstdate_begin_is_datetime PASSED [100%]

===== 11 passed in 55.74s =====
```



CONCLUSION

- ✓ Mise en place d'un POC RAG de recommandation d'événements culturels
- ✓ Collecte, nettoyage et indexation des données OpenAgenda
Utilisation des embeddings et de FAISS pour la recherche sémantique
- ✓ Développement d'un chatbot Flask capable de répondre aux utilisateurs
- ✓ Validation fonctionnelle du pipeline et des traitements

MERCI !

