



GÉREZ UN PROJET D'INFRASTRUCTURE

Projet Data Engineer | Sophana SEAN

PRÉSENTATION



CONTEXTE

Sport Data Solution souhaite encourager la pratique sportive de ses collaborateurs à travers un programme d'avantages comprenant des primes et des journées bien-être.

Un **POC** est réalisé afin de valider la faisabilité technique, les règles métier et l'impact financier du dispositif.




OBJECTIFS


1. Collecter les données RH et sportives
2. Calculer l'éligibilité des salariés
3. Génération des activités sportives
4. Contrôler la qualité des données
5. Envoyer des notifications Slack
6. Orchestrer les traitements avec Kestra
7. Visualiser les indicateurs dans un dashboard Flask

ARCHITECTURE DE LA PIPELINE

Schéma du pipeline Sport Data Solution



01 - COLLECTE DES DONNÉES



IMPORT DES DONNÉES RH

Récupération des informations collaborateurs et données sportives.

Source :


Données_RH.xlsx
Données_Sportive.xlsx



CONTRÔLE DES DONNÉES

Vérification :

colonnes obligatoires
valeurs manquantes
types de données
cohérence des identifiants



CRÉATION DE LA BDD

Création automatique des tables :

employés
activités_sportives
eligibilite

Sortie SQLite:
avantages_sportifs.db



GÉNÉRATION DES ACTIVITÉS

Création de plusieurs milliers d'activités sportives sur les 12 derniers mois pour alimenter le POC.

02 - CALCULER L'ÉLIGIBILITÉ DES SALARIÉS

01.

PRIME SPORTIVE

Un salarié peut bénéficier d'une prime de **5 % du salaire annuel brut** s'il vient au bureau avec un mode de déplacement sportif. (vélo, marche, course à pied...)

02.

JOURNÉES BIEN-ÊTRE

Un salarié peut obtenir **5 journées bien-être** par an s'il pratique une activité physique régulière et soutenue.

Calculer des **distances** entre le domicile salarié et adresse entreprise avec **Google Maps API**.

Détecter des incohérences si le mode de déplacement déclaré est réaliste.

- 42 km en marche
- distance domicile/travail trop élevée
- activité manquante
- salarié non référencé

03 - GÉNÉRATION DES ACTIVITÉS SPORTIVES

La deuxième étape consiste à créer un volume réaliste de données sportives afin de tester les règles métier, les calculs d'éligibilité et le pipeline de traitement.

GÉNÉRATION D'ACTIVITÉS RÉALISTES

Pour chaque salarié, le script génère entre **10 à 80 activités sportives** réparties sur **les 12 derniers mois**.

disciplines :

Course à pied, Vélo, Marche
Randonnée, Natation
Escalade

CALCUL DES PERFORMANCES

Pour chaque activité :

- distance parcourue
- durée de l'effort
- date et heure réalistes
- commentaire associé

STOCKAGE DANS LA BDD

Les activités sont enregistrées dans la table **activites_sportives** permettant de :

- tester le calcul des avantages
- alimenter les indicateurs RH
- produire des statistiques sportives
- simuler un environnement réel

04 - QUALITÉ DES DONNÉES AVEC GREAT EXPECTATIONS

great expectations Home / Validations / activites_suite / __none__ / 2026-06-08T16:39:46Z

Expectation Validation Result

Evaluates whether a batch of data matches expectations.

Actions

Validation Filter:

Show All Failed Only

How to Edit This Suite

Table of Contents

- Overview
- Table-Level Expectations
- date_debut
- date_fin
- distance_m
- id
- id_salarie
- type_activite

Overview

Expectation Suite: [activites_suite](#)

Data asset: None

Status: ✔ Succeeded

Statistics

Statistics	
Evaluated Expectations	8
Successful Expectations	8
Unsuccessful Expectations	0
Success Percent	100%

Show more info...

Table-Level Expectations

Status	Expectation
✔	Values in date_fin must be...

Le système vérifie que les activités respectent les règles attendues :

- distances positives
- durées positives
- dates valides
- types de sports autorisés
- salariés existants dans la base RH
- unicité des identifiants


Great Expectations permet de contrôler automatiquement les données présentes dans SQLite.

Ces contrôles permettent d'identifier rapidement :

- activité sans salarié associé
- distance incohérente
- date de fin avant date de début
- sport non reconnu
- valeur manquante sur un champ important

05 - ENVOYER DES NOTIFICATIONS SLACK

- Le projet est connecté à Slack via un **Webhook entrant**.
- Chaque exécution du pipeline peut publier automatiquement des messages dans le canal dédié.
- Les 10 dernières activités enregistrées sont automatiquement publiées afin d'encourager la pratique sportive.



06 - ORCHESTRER LES TRAITEMENTS AVEC KESTRA

Kestra joue le rôle d'orchestrateur du pipeline. Il exécute automatiquement les différentes étapes dans le bon ordre, supervise les traitements et centralise les logs d'exécution.

Kestra pilote automatiquement les différentes étapes du projet :

Création et mise à jour de la base SQLite



Génération des activités sportives




Calcul de l'éligibilité



Contrôles qualité Great Expectations



Notifications Slack



EXÉCUTION

automatique

manuelle

Exécution tous les jours à 6h

Trigger details: daily	
Name	Value
Id	daily
Type	io.kestra.plugin.core.trigger.Schedule
Cron	At 06:00 AM


Le taux de prime est paramétrable

Execute the flow `p12_sport`

*** Taux de prime**

Taux appliqué au salaire annuel brut. Exemple 0.05 = 5 %

07 - VISUALISER LES INDICATEURS DANS UN DASHBOARD FLASK



Le dashboard centralise les principaux indicateurs :

- ❖ nombre total de salariés
- ❖ nombre de salariés éligibles
- ❖ coût total des primes
- ❖ nombre de jours bien-être attribués
- ❖ répartition des activités sportives
- ❖ évolution des activités par mois
- ❖ dernières activités

Le dashboard est développé avec :

- Flask pour l'application web
- SQLite pour les données
- Chart.js pour les graphiques
- HTML / CSS / JavaScript pour l'interface



CONCLUSION



Au cours de ce projet, nous avons développé un POC complet de gestion des avantages sportifs destiné aux collaborateurs de Sport Data Solution.



La solution apporte plusieurs bénéfices comme la promotion de la pratique sportive et amélioration du bien-être des collaborateurs.



Ce projet a permis de mettre en œuvre un pipeline Data Engineering complet intégrant : collecte, stockage, transformation, qualité des données, orchestration, monitoring et visualisation.



MERCI !